

NAMA : Sultan Maulana Prayoga
KELAS : SI-REG-P1
PRODI : Sistem Informasi
MATKUL : Data Science

Membangun Model Regresi

Model regresi adalah teknik statistik yang digunakan untuk memodelkan dan menganalisis hubungan antara dua variabel atau lebih. Tujuannya adalah untuk memperkirakan bagaimana satu variabel, yang disebut variabel dependen (variabel terikat), dipengaruhi oleh satu atau lebih variabel lainnya, yang disebut variabel independen (variabel bebas).

Kegunaan Utama Analisis Regresi :

1. Memahami tujuan pembangunan model dalam konteks eksplorasi data (exploratory data analysis).
2. Menggunakan model linier sederhana untuk mengidentifikasi dan menghilangkan pola utama dari data.
3. Menganalisis residual untuk menemukan tren sekunder, outlier, dan struktur tersembunyi.
4. Menggabungkan teknik transformasi data dan pemodelan untuk memperdalam pemahaman tentang dataset.

Cek Apakah betul diamond dengan cut (fair) rata-rata harganya tinggi

Langkah awal memasukan data set diamond ke proyek dengan menginstal

Library (tidyverse) dan library (modelr) untuk mempermudah proses pemodelan

hasil menunjukkan bahwa kualitas potongan "Premium" dan "Fair" memiliki harga rata-rata yang lebih tinggi daripada potongan "Ideal".

Meskipun "Ideal" adalah kualitas potongan terbaik, berlian dengan potongan "Premium" dan "Fair" sering kali memiliki karat yang lebih besar (walaupun kualitas potongannya lebih

rendah), dan karena karat adalah faktor pendorong harga terbesar, rata-rata harga untuk potongan yang lebih rendah dapat menjadi lebih tinggi.

```
> diamonds %>%
+   group_by(cut) %>%
+   summarise(avg_price = mean(price)) %>%
+   arrange(desc(avg_price))
# A tibble: 5 x 2
  cut      avg_price
<ord>      <dbl>
1 Premium    4584.
2 Fair       4359.
3 Very Good  3982.
4 Good       3929.
5 Ideal      3458.
>
```

Tampilkan informasi dasar tentang dataset

Terdapat Tipe Data Penting:

<dbl> (Double): Angka desimal (misalnya, berat, dimensi).

<int> (Integer): Angka bulat (misalnya, harga).

<ord> (Ordered Factor): Variabel kategori yang memiliki urutan alami (misalnya, kualitas potongan dari "Fair" hingga "Ideal").

```
> glimpse(diamonds)
Rows: 53,940
Columns: 11
$ carat    <dbl> 0.23, 0.21, 0.23, 0.29, 0.31, 0.24, 0.24, 0.26, 0.22, 0.23, 0.2...
$ cut      <ord> Ideal, Premium, Good, Premium, Good, Very Good, Very Good, Ver...
$ color    <ord> E, E, E, I, J, J, I, H, E, H, J, J, F, J, E, E, I, J, J, J, I,...
$ clarity  <ord> SI2, SI1, VS1, VS2, SI2, VVS2, VVS1, SI1, VS2, VS1, SI1, VS1, ...
$ depth    <dbl> 61.5, 59.8, 56.9, 62.4, 63.3, 62.8, 62.3, 61.9, 65.1, 59.4, 64...
$ table    <dbl> 55, 61, 65, 58, 58, 57, 57, 55, 61, 61, 55, 56, 61, 54, 62, 58...
$ price    <int> 326, 326, 327, 334, 335, 336, 336, 337, 337, 338, 339, 340, 34...
$ x        <dbl> 3.95, 3.89, 4.05, 4.20, 4.34, 3.94, 3.95, 4.07, 3.87, 4.00, 4.0...
$ y        <dbl> 3.98, 3.84, 4.07, 4.23, 4.35, 3.96, 3.98, 4.11, 3.78, 4.05, 4.0...
$ z        <dbl> 2.43, 2.31, 2.31, 2.63, 2.75, 2.48, 2.47, 2.53, 2.49, 2.39, 2.4...
$ pred_price <dbl> -1906.470570, -1265.313682, -340.028577, -1138.901677, -3651.6...
```

Memiliki 53,940 baris / Rows dan 11 kolom

Eksplorasi Data Awal (EDA)


Periksa Distribusi Harga (price)

```
> #visualisasi distribusi
> ggplot(diamonds,aes(x = price)) +
+   geom_histogram(bins = 50, fill = "skyblue", color = "black") +
+   labs(title = "Distribusi Harga Berlian")
>
```

Bentuk distribusi ini mengimplikasikan:

Mayoritas Murah adalah Sebagian besar berlian dalam *dataset* ini tergolong berlian kecil atau dengan kualitas standar (seperti yang terlihat dari tingginya *count* di rentang harga rendah).

Data Outliers pada Berlian dengan harga yang sangat tinggi (*high-value diamonds*) bertindak sebagai *outliers* yang menarik rata-rata harga ke kanan (ke nilai yang lebih tinggi), meskipun jumlahnya sedikit.




Statistik deskripsi Harga (price)

Statistik	Nilai (Price)
Min. (Minimum)	326
1st Qu. (Kuartil Pertama, Q1)	950
Median (Kuartil Kedua, Q2)	2401
Mean (Rata-rata)	3933
3rd Qu. (Kuartil Ketiga, Q3)	5324
Max. (Maksimum)	18823

```
>
> #statistik deskriptip harga(price)
> summary(diamonds$price)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   326    950    2401   3933   5324  18823
```

Hubungan Utama : karat vs harga


```
>
> #hubungan antara karat vs harga
> #scatterplot
> ggplot(diamonds,aes(x = carat, y = price)) +
+   geom_point(alpha = 0.1) +
+   labs(title = "Hubungan antar karat dan harga")
>
```



Informasi Log melihat hubungan non-linear

```
>
> #Gunakan informasi log untuk melihat hubungan non - linear
> ggplot(diamonds, aes(x = log(carat), y = log(price))) +
+   geom_bin2d()+
+   labs(title = "log(harga) vs log(price)")
`stat_bin2d()` using `bins = 30`. Pick better value `binwidth`
> |
```

Insight: Hubungan antara karat dan harga bersifat eksponensial. Menggunakan $\log()$ akan membuatnya lebih linear.



Memfilter terlebih dahulu data fokus pada berlian yang lebih umum

```
#Filter data fokus pada berlian yang lebih umum
diamonds2 <- diamonds %>%
  filter(carat <= 2.5)
```

|

Transformasi Logaritmik, untuk mengubah carat dan price ke skala log untuk hubungan yang lebih linear

```
<
> # B. Transformasi Logaritmik
> # Ubah carat dan price ke skala log untuk hubungan yang lebih linier.
> diamonds2 <- diamonds2 %>%
+   mutate(lprice = log2(price),
+          lcarat = log2(carat))
~ |
```

Menggunakan transformasi logaritma pada variabel yang miring ke kanan (seperti price dan carat) dapat membantu mencapai hubungan yang lebih linier dan memenuhi asumsi model regresi.

Periksa Outlier pada Dimensi Fisik

Hasil (Output)

A tibble: 16,585 x 5: Menunjukkan bahwa 16.585 baris data (berlian) memenuhi setidaknya satu kriteria filter tersebut.

Data yang Ditampilkan: Menunjukkan contoh 10 baris pertama dari data yang terdeteksi, di mana dimensi x, y, dan z tampaknya berada dalam rentang rendah (di bawah 5 mm) dan harga berlian juga rendah. Ini mengkonfirmasi bahwa sebagian besar berlian memiliki dimensi

kecil; kriteria filter ini menangkap sebagian besar berlian kecil (bukan hanya *outlier* yang jelas), terutama kriteria {x < 3} dan {z < 3}.

```
> # periksa outlier pada dimensi fisik
> # periksa nilai x, y, z yang tidak masuk akal
> diamonds2 %>%
+   filter(y < 3 | y > 20 | x < 3 | z < 3) %>%
+   select(carat, x, y, z, price)
# A tibble: 16,585 x 5
   carat      x      y      z price
  <dbl> <dbl> <dbl> <dbl> <int>
1  0.23  3.95  3.98  2.43   326
2  0.21  3.89  3.84  2.31   326
3  0.23  4.05  4.07  2.31   327
4  0.29  4.2   4.23  2.63   334
5  0.31  4.34  4.35  2.75   335
6  0.24  3.94  3.96  2.48   336
7  0.24  3.95  3.98  2.47   336
8  0.26  4.07  4.11  2.53   337
9  0.22  3.87  3.78  2.49   337
10 0.23  4     4.05  2.39   338
# i 16,575 more rows
# i Use `print(n = ...)` to see more rows
```

Ganti Outlier

Mengganti *outlier* dengan NA adalah praktik yang disarankan karena memungkinkan metode pemodelan untuk mengelola nilai-nilai yang hilang tersebut secara tepat.

```
> # ganti outlier
> #ganti outlier dengan NA (opsional, tapi disarankan)
> diamonds2 <-diamonds %>%
+   mutate(
+     x = ifelse(x < 3 | x > 30, NA, x),
+     y = ifelse(y < 3 | y > 30, NA, x),
+     z = ifelse(z < 3 | z > 30, NA, x)
+   )
.
```

Membuat masing masing model

Model 1 : hanya karat

```
<
> # A. Model 1: Hanya Karat
> # Model paling sederhana: prediksi harga dari ukuran karat (lcarat yang sudah di-log).
> mod1 <- lm(lprice ~ lcarat, data = diamonds2)
.
```

Model 2 : menambahkan kualitas potongan (cut)

```
> # B. Model 2: Tambahkan Kualitas Potongan (cut)
> # Menambahkan variabel kategorikal 'cut'.
> mod2 <- lm(lprice ~ lcarat + cut, data = diamonds2)
```

Model 3 : model lengkap dengan semua prediktor + warna + kejernihan

```
> # C. Model 3: Tambahkan warna (color) dan kejernihan (clarity)
> # Model lengkap dengan semua prediktor kualitas berlian (4C).
> mod3 <- lm(lprice ~ lcarat + cut + color + clarity, data = diamonds2)
.
```

Ringkasan Model (Menggunakan broom::tidy())

Interpretasi:

lcarat: Koefisien positif besar → semakin besar karat, semakin mahal.

cutIdeal: Positif → potongan "Ideal" meningkatkan harga relatif.

colorE: Positif → warna "E" lebih mahal dari referensi "D".

claritySI2: Negatif → kejernihan rendah menurunkan harga.

```
> #ringkasan model
> #lihat koefisien dari mod3
> tidy(mod3) %>%
+   arrange(desc(abs(estimate))) %>%
+   print(n = 15)
# A tibble: 19 x 5
  term                estimate std.error statistic  p.value
  <chr>              <dbl>    <dbl>    <dbl>    <dbl>
1 (Intercept)      12.2      0.00169    7212.    0
2 lcarat           1.89      0.00112   1678.    0
3 clarity.L         1.31      0.00518    253.    0
4 color.L          -0.634     0.00291   -218.    0
5 clarity.Q        -0.334     0.00484   -69.0    0
6 clarity.C         0.178     0.00414    43.1    0
7 cut.L            0.174     0.00339    51.3    0
8 color.Q          -0.138     0.00268   -51.4    0
9 clarity^4        -0.0881    0.00330   -26.7    5.33e-156
10 cut.Q           -0.0503    0.00298   -16.9    6.89e- 64
11 clarity^7        0.0482    0.00205    23.5    1.28e-121
12 clarity^5        0.0359    0.00268    13.4    8.12e- 41
13 color.C         -0.0221    0.00250    -8.82   1.19e- 18
14 cut.C            0.0191    0.00258     7.41   1.31e- 13
15 color^4          0.0166    0.00230     7.21   5.54e- 13
# i 4 more rows
# i Use `print(n = ...)` to see more rows
```

Ringkasan Model secara keseluruhan


```
> #ringkasan model secara keseluruhan
> glance(mod3)
# A tibble: 1 x 12
  r.squared adj.r.squared sigma statistic p.value    df logLik   AIC    BIC deviance
  <dbl>      <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl> <dbl>    <dbl>
1  0.983      0.983 0.192   170643.    0     18 12582. -25124. -24946.   1974.
# i 2 more variables: df.residual <int>, nobs <int>
.
```

Visualisasi Prediksi

Lihat model memprediksi harga rata-rata

Membuat grid data baru

```
> # Buat grid data baru
> grid <- diamonds2 %>%
+   data_grid(cut, .model = mod3) %>%
+   add_predictions(mod3, "pred_lprice") %>%
+   mutate(pred_price = 2^pred_lprice) # kembalikan ke skala asli
>
> # Plot prediksi
> ggplot(grid, aes(x = cut, y = pred_price)) +
+   geom_point(size = 3, color = "red") +
+   labs(title = "Harga Prediksi Rata-Rata per Jenis Potongan")
\
```



Kode ini:

- Membuat grid data berdasarkan variabel cut dari dataset diamonds2.
- Menambahkan kolom prediksi dari model mod3.
- Mengubah hasil log (base 2) kembali ke skala harga asli.
- Menampilkan hasil prediksi menggunakan scatter plot (geom_point) dengan warna merah.

Analisis Residual (Pemeriksaan Asumsi & Insight)

Hitung residual


```
> #analisis residual
> diamonds2 <- diamonds2 %>%
+   add_residuals(mod3, "resid_lprice")
~
```

Menambahkan kolom

```
> #plot1 residual vs nilai prediksi
> diamonds2 <- diamonds2 %>%
+   add_predictions(mod3, "pred_lprice") # Menambahkan kolom 'pred_lprice'
>
```

Menampilkan plot


```
ggplot(diamonds2, aes(x = pred_lprice, y = resid_lprice)) +
  geom_point(alpha = 0.1) +
  geom_hline(yintercept = 0, color = "red", linetype = "dashed") +
  labs(
    title = "Residual vs Prediksi (log scale)",
    x = "Prediksi log(Harga)",
    y = "Residual (log scale)"
  )
```



Harapan: Titik tersebar acak di sekitar nol. Jika ada pola (seperti corong), model kurang baik.

Plot 2 : Histogram Residual

```
ggplot(diamonds2, aes(x = resid_lprice)) +  
  geom_histogram(bins = 50, fill = "green", alpha = 0.7) +  
  geom_vline(xintercept = 0, color = "red", linetype = "dashed") +  
  labs(title = "Distribusi Residual")
```



Harapan: Berbentuk lonceng (normal). Jika miring, ada bias sistematis.

Gunakan `rsquare()` untuk membandingkan model.

```
>  
> rsquare(mod1, diamonds2)  
[1] 0.9334026  
> rsquare(mod2, diamonds2)  
[1] 0.9374585  
> rsquare(mod3, diamonds2)  
[1] 0.9827876  
>
```

